analise_drivers

October 12, 2026

1 PixPay — Drivers de churn

Entrada: `data/clientes_pixpay_limpo.csv` (somente leitura). Funções em `scripts/analisar_drivers.py`. Tudo aqui é **associação, não causalidade**.

[1]:
```
import sys
from pathlib import Path

RAIZ = next(p for p in (Path.cwd(), Path.cwd().parent) if (p / "scripts").
 ↪exists())
sys.path.insert(0, str(RAIZ / "scripts"))

import matplotlib.pyplot as plt
import pandas as pd
import analisar_drivers as ad
from investigar_transacoes import carregar_limpo

pd.set_option("display.width", 200)
df = carregar_limpo(RAIZ / "data" / "clientes_pixpay_limpo.csv")
df.shape
```

[1]:
```
(10000, 16)
```

1.1 Passo 1 — Validar a premissa do briefing (churn real vs. 8%)

Hipótese a testar: o churn mensal é 8%. Calculamos o churn de abril/2026 com três denominadores, com IC 95% (Wilson).

[2]:
```
r1 = ad.validar_premissa(df)
r1["denominadores"]
```

[2]:
```
                           denominador  clientes  cancelaram  churn_%
ic95_inferior_%  ic95_superior_%  diferenca_vs_8%_pp
0          Base total (todas as linhas)     10000        1353    13.53
12.87            14.21                5.53
1       Cadastrados antes de 01/04/2026      9990        1352    13.53
12.88            14.22                5.53
2  Ativos em 01/04/2026 (início do mês)      9990        1352    13.53
```

```
12.88            14.22                5.53
```

1.1.1 O dataset consegue mostrar a tendência de 6 meses?

[3]:
```
pd.Series(r1["cobertura"], name="valor").to_frame()
```

[3]:

	valor
cadastro_min	01/01/2024
cadastro_max	01/04/2026
cancelamento_min	01/04/2026
cancelamento_max	30/04/2026
meses_distintos_com_cancelamento	1
cancelamentos_total	1353
cancelamentos_antes_de_01/04/2026	0
cadastros_em_ou_apos_01/04/2026	10
cancelaram_e_cadastrados_em_ou_apos_01/04	1

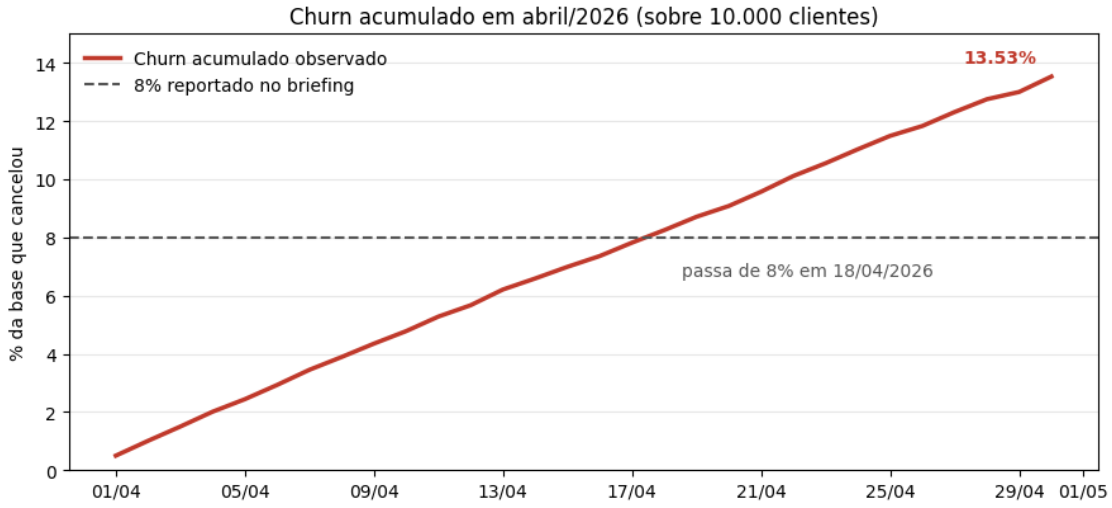
1.1.2 O que seria preciso para o churn ser 8%?

[4]:
```
pd.Series(r1["reversa"], name="valor").to_frame()
```

[4]:

	valor
cancelamentos_necessarios_para_8%_da_base	800
cancelamentos_observados	1353
excesso_vs_8%	553
base_necessaria_para_8%_com_1353_cancelamentos	16912
dia_de_abril_em_que_o_acumulado_chega_a_8%	18/04/2026

[5]:
```
fig = ad.grafico_churn_acumulado(df)
fig.savefig(RAIZ / "reports" / "passo1_churn_acumulado_abril.png", dpi=150)
plt.show()
```



[6]:
```
r1["por_dia"]
```

[6]:

data	cancelamentos	acumulado	churn_acumulado_%
01/04/2026	50	50	0.50
02/04/2026	51	101	1.01
03/04/2026	49	150	1.50
04/04/2026	51	201	2.01
05/04/2026	43	244	2.44
06/04/2026	49	293	2.93
07/04/2026	52	345	3.45
08/04/2026	44	389	3.89
09/04/2026	46	435	4.35
10/04/2026	43	478	4.78
11/04/2026	50	528	5.28
12/04/2026	39	567	5.67
13/04/2026	54	621	6.21
14/04/2026	38	659	6.59
15/04/2026	40	699	6.99
16/04/2026	37	736	7.36
17/04/2026	46	782	7.82
18/04/2026	43	825	8.25
19/04/2026	46	871	8.71
20/04/2026	37	908	9.08
21/04/2026	49	957	9.57
22/04/2026	54	1011	10.11
23/04/2026	44	1055	10.55
24/04/2026	48	1103	11.03
25/04/2026	46	1149	11.49
26/04/2026	34	1183	11.83
27/04/2026	48	1231	12.31
28/04/2026	44	1275	12.75
29/04/2026	25	1300	13.00
30/04/2026	53	1353	13.53

1.2 Passo 2 — Drivers por categoria

Para cada variável: churn por grupo, IC 95% (Wilson) e teste global de permutação (5.000 repetições, semente 0). Limite de significância com Bonferroni para 9 testes: $\mathbf{p < 0{,}0056}$. Grupos com n < 50 são agrupados, nunca descartados.

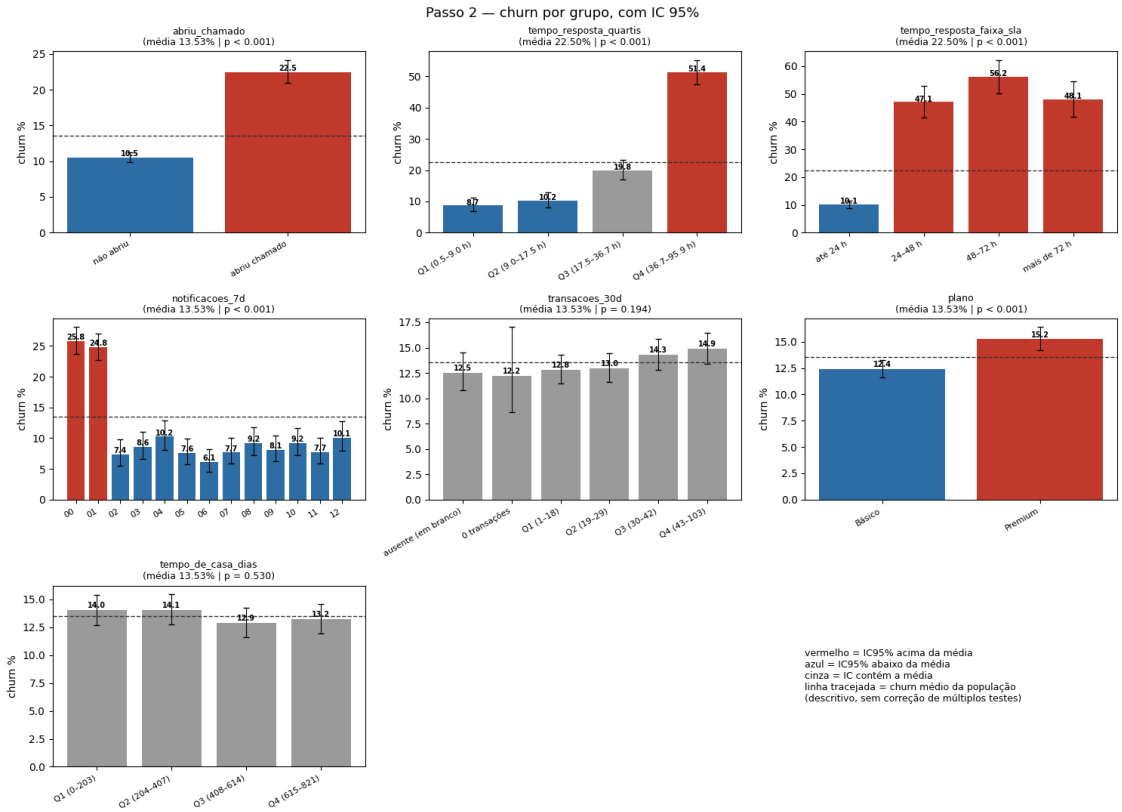
Cuidados: `tempo_resposta` só existe para quem abriu chamado; `transacoes_30d` mantém "ausente" e "0" separados (nada foi alterado nos dados); tempo de casa usa 01/04/2026 como referência para não vazar o desfecho.

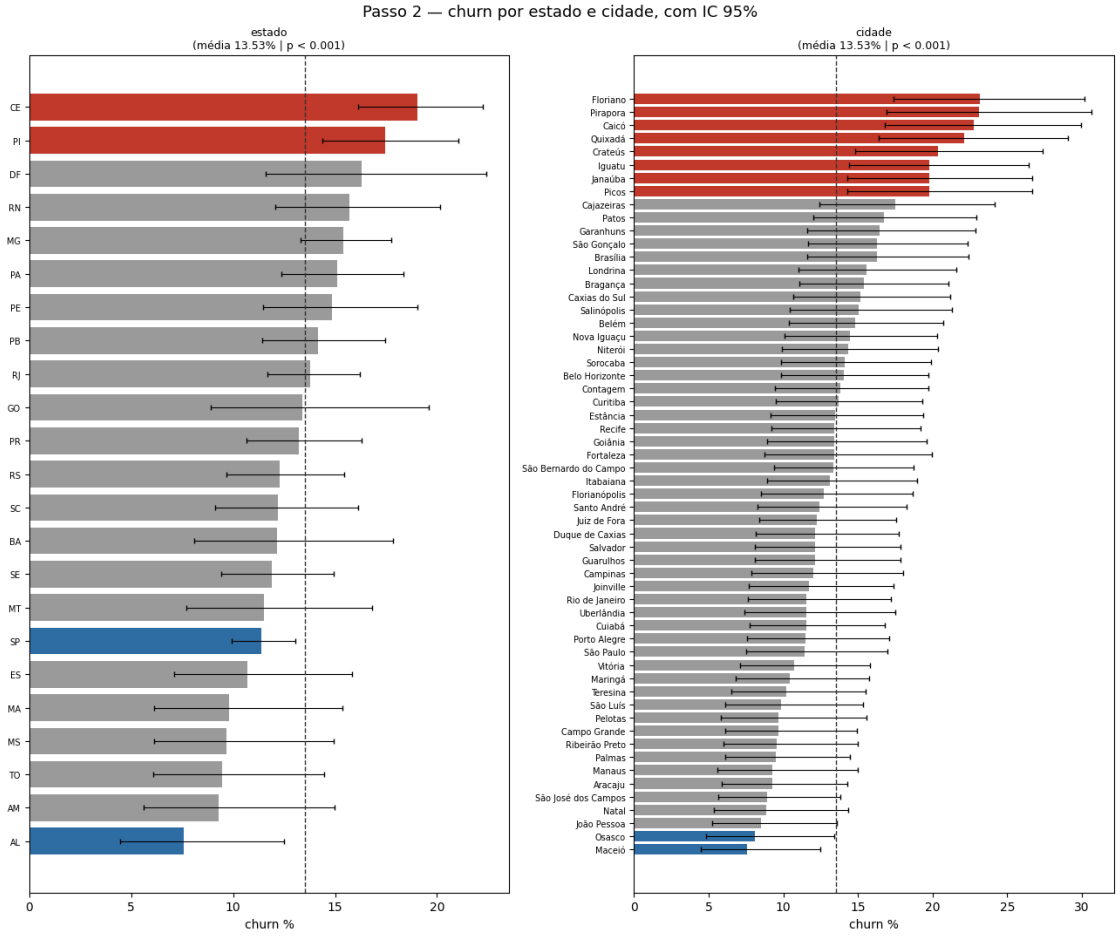
[7]:
```
p2 = ad.analisar_drivers(df)
p2["resumo"]
```

[7]:

	categoria	variavel	n	churn_pop_%	grupos	churn_min_%	churn_max_%	amplitude_pp	qui2	p_permutacao	significativo_bonferroni
0	Contextual	abriu_chamado	10000	13.53	2	10.50	22.50	12.00	232.39	0.0002	True
1	Contextual	tempo_resposta_quartis	2524	22.50	4	8.68	51.35	42.67	427.64	0.0002	True
2	Contextual	tempo_resposta_faixa_sla	2524	22.50	4	10.08	56.25	46.17	508.93	0.0002	True
3	Comportamental	notificacoes_7d	10000	13.53	13	6.13	25.82	19.69	530.03	0.0002	True
4	Comportamental	transacoes_30d	10000	13.53	6	12.24	14.88	2.64	7.31	0.1942	False
5	Demográfica	plano	10000	13.53	2	12.39	15.23	2.84	16.59	0.0002	True
6	Demográfica	estado	10000	13.53	23	7.56	19.02	11.46	55.56	0.0002	True
7	Demográfica	cidade	10000	13.53	58	7.56	23.17	15.61	123.54	0.0002	True
8	Controle	tempo_de_casa_dias	10000	13.53	4	12.86	14.05	1.19	2.24	0.5299	False

[8]:
```
fig1, fig2 = ad.graficos_passo2(p2)
fig1.savefig(RAIZ / "reports" / "passo2_churn_por_variavel.png", dpi=130)
fig2.savefig(RAIZ / "reports" / "passo2_churn_geografia.png", dpi=130)
plt.show()
```


Passo 2 — churn por grupo, com IC 95%
abriu_chamado
(média 13.53% | p < 0.001)
churn %
10.5
22.5
não abriu
abriu chamado
tempo_resposta_quartis
(média 22.50% | p < 0.001)
churn %
8.7
10.2
19.8
51.4
Q1 (0.5–9.0 h)
Q2 (9.0–17.5 h)
Q3 (17.5–36.7 h)
Q4 (36.7–95.9 h)
tempo_resposta_faixa_sla
(média 22.50% | p < 0.001)
churn %
10.1
47.1
56.2
48.1
até 24 h
24–48 h
48–72 h
mais de 72 h
notificacoes_7d
(média 13.53% | p < 0.001)
churn %
25.8
24.8
7.4
8.6
10.2
7.6
6.1
7.7
9.2
8.1
9.2
7.7
10.1
00
01
02
03
04
05
06
07
08
09
10
11
12
transacoes_30d
(média 13.53% | p = 0.194)
churn %
12.5
12.2
12.8
13.0
14.3
14.9
ausente (em branco)
0 transações
Q1 (1–18)
Q2 (19–29)
Q3 (30–42)
Q4 (43–103)
plano
(média 13.53% | p < 0.001)
churn %
12.4
15.2
Básico
Premium
tempo_de_casa_dias
(média 13.53% | p = 0.530)
churn %
14.0
14.1
12.9
13.2
Q1 (0–203)
Q2 (204–407)
Q3 (408–614)
Q4 (615–821)
vermelho = IC95% acima da média
azul = IC95% abaixo da média
cinza = IC contém a média
linha tracejada = churn médio da população
(descritivo, sem correção de múltiplos testes)



1.2.1 abriu_chamado

[9]:
```
print(p2["definicoes"]["abriu_chamado"]["nota"])
p2["variaveis"]["abriu_chamado"]["tabela"]
```

```
população: 10.000
```

[9]:

grupo	clientes	cancelaram	churn_%	ic95_inf_%	ic95_sup_%	dif_vs_media_pp	ic_exclui_a_media
não abriu	7476	785	10.5	9.83	11.22	-3.03	True
abriu chamado	2524	568	22.5	20.92	24.17	8.97	True

1.2.2 tempo_resposta_quartis

[10]:
```
print(p2["definicoes"]["tempo_resposta_quartis"]["nota"])
p2["variaveis"]["tempo_resposta_quartis"]["tabela"]
```

```
população: só quem abriu chamado (n = 2.524)
```

[10]:

grupo	clientes	cancelaram	churn_%	ic95_inf_%	ic95_sup_%	dif_vs_media_pp	ic_exclui_a_media
Q1 (0.5-9.0 h)	634	55	8.68	6.73	11.12	-13.82	True
Q2 (9.0-17.5 h)	634	65	10.25	8.13	12.86	-12.25	True
Q3 (17.5-36.7 h)	625	124	19.84	16.90	23.15	-2.66	False
Q4 (36.7-95.9 h)	631	324	51.35	47.45	55.23	28.85	True

1.2.3 tempo_resposta_faixa_sla

[11]:
```
print(p2["definicoes"]["tempo_resposta_faixa_sla"]["nota"])
p2["variaveis"]["tempo_resposta_faixa_sla"]["tabela"]
```

```
população: só quem abriu chamado; faixas de SLA em horas
```

[11]:

grupo	clientes	cancelaram	churn_%	ic95_inf_%	ic95_sup_%	dif_vs_media_pp	ic_exclui_a_media
até 24 h	1746	176	10.08	8.75	11.58	-12.42	True
24-48 h	289	136	47.06	41.38	52.81	24.56	True
48-72 h	256	144	56.25	50.13	62.19	33.75	True
mais de 72 h	233	112	48.07	41.74	54.46	25.57	True

1.2.4 notificacoes_7d

[12]:
```
print(p2["definicoes"]["notificacoes_7d"]["nota"])
p2["variaveis"]["notificacoes_7d"]["tabela"]
```

```
população: 10.000
```

[12]:

grupo	clientes	cancelaram	churn_%	ic95_inf_%	ic95_sup_%	dif_vs_media_pp	ic_exclui_a_media
00	1522	393	25.82	23.69	28.08	12.29	

```
True
01          1527          379    24.82        22.72        27.05             11.29
True
02           580           43     7.41         5.55         9.84             -6.12
True
03           618           53     8.58         6.62        11.05             -4.95
True
04           605           62    10.25         8.08        12.92             -3.28
True
05           658           50     7.60         5.81         9.88             -5.93
True
06           636           39     6.13         4.52         8.27             -7.40
True
07           623           48     7.70         5.86        10.07             -5.83
True
08           638           59     9.25         7.24        11.75             -4.28
True
09           656           53     8.08         6.23        10.42             -5.45
True
10           674           62     9.20         7.24        11.62             -4.33
True
11           648           50     7.72         5.90        10.03             -5.81
True
12           615           62    10.08         7.94        12.71             -3.45
True
```

1.2.5 transacoes_30d

[13]:
```
print(p2["definicoes"]["transacoes_30d"]["nota"])
p2["variaveis"]["transacoes_30d"]["tabela"]
```

```
população: 10.000; ausente e 0 separados
```

[13]:

grupo	clientes	cancelaram	churn_%	ic95_inf_%	ic95_sup_%	dif_vs_media_pp	ic_exclui_a_media
ausente (em branco)	1215	152	12.51	10.77	14.49	-1.02	False
0 transações	237	29	12.24	8.66	17.02	-1.29	False
Q1 (1-18)	2158	276	12.79	11.45	14.27	-0.74	False
Q2 (19-29)	2221	288	12.97	11.63	14.43	-0.56	False
Q3 (30-42)	2045	292	14.28	12.83	15.86	0.75	False
Q4 (43-103)	2124	316	14.88	13.43	16.45	1.35	False

1.2.6 plano

[14]:
```
print(p2["definicoes"]["plano"]["nota"])
p2["variaveis"]["plano"]["tabela"]
```

```
população: 10.000
```

[14]:

grupo	clientes	cancelaram	churn_%	ic95_inf_%	ic95_sup_%	dif_vs_media_pp	ic_exclui_a_media
Básico	5996	743	12.39	11.58	13.25	-1.14	True
Premium	4004	610	15.23	14.16	16.38	1.70	True

1.2.7 tempo_de_casa_dias

[15]:
```
print(p2["definicoes"]["tempo_de_casa_dias"]["nota"])
p2["variaveis"]["tempo_de_casa_dias"]["tabela"]
```

```
dias de cadastro até 01/04/2026
```

[15]:

grupo	clientes	cancelaram	churn_%	ic95_inf_%	ic95_sup_%	dif_vs_media_pp	ic_exclui_a_media
Q1 (0-203)	2506	351	14.01	12.70	15.42	0.48	False
Q2 (204-407)	2499	351	14.05	12.74	15.46	0.52	False
Q3 (408-614)	2497	321	12.86	11.60	14.23	-0.67	False
Q4 (615-821)	2498	330	13.21	11.94	14.60	-0.32	False

1.2.8 estado e cidade — 5 maiores e 5 menores

[16]:
```
for nome in ("estado", "cidade"):
    t = p2["variaveis"][nome]["tabela"]
    print(nome, "| IC exclui a média em", int(t["ic_exclui_a_media"].sum()),␣
 ↪"de", len(t), "grupos")
    display(pd.concat([t.head(5), t.tail(5)])[["clientes", "cancelaram",␣
 ↪"churn_%", "ic95_inf_%", "ic95_sup_%", "dif_vs_media_pp"]])
```

```
estado | IC exclui a média em 4 de 23 grupos
```

grupo	clientes	cancelaram	churn_%	ic95_inf_%	ic95_sup_%	dif_vs_media_pp
CE	631	120	19.02	16.15	22.26	5.49
PI	498	87	17.47	14.39	21.05	3.94
DF	178	29	16.29	11.59	22.42	2.76

```
RN          312          49    15.71       12.09       20.16             2.18
MG         1019         157    15.41       13.32       17.75             1.88
MA          163          16     9.82        6.13       15.35            -3.71
MS          176          17     9.66        6.12       14.92            -3.87
TO          190          18     9.47        6.08       14.48            -4.06
AM          151          14     9.27        5.60       14.96            -4.26
AL          172          13     7.56        4.47       12.50            -5.97
```

```
cidade | IC exclui a média em 10 de 59 grupos
```

```
                            clientes  cancelaram  churn_%  ic95_inf_% ␣
 ↪ic95_sup_%  dif_vs_media_pp
grupo
Floriano                         164          38    23.17       17.37       30.
 ↪20             9.64
Pirapora                         143          33    23.08       16.93       30.
 ↪63             9.55
Caicó                            154          35    22.73       16.82       29.
 ↪96             9.20
Quixadá                          163          36    22.09       16.40       29.
 ↪06             8.56
Crateús                          157          32    20.38       14.82       27.
 ↪36             6.85
Natal                            158          14     8.86        5.35       14.
 ↪32            -4.67
João Pessoa                      176          15     8.52        5.23       13.
 ↪58            -5.01
Osasco                           160          13     8.12        4.81       13.
 ↪40            -5.41
Maceió                           172          13     7.56        4.47       12.
 ↪50            -5.97
(grupos pequenos agrupados)        3           0     0.00        0.00       56.
 ↪15           -13.53
```

1.2.9 Checagem de confusão: chamado × tempo de resposta, e sobreposição dos dois principais sinais

[17]:
```
baixo = df["notificacoes_7d"] <= 1
lento = df["abriu_chamado"] & (df["tempo_resposta_chamado_h"] > 24)
conf = pd.DataFrame({
    "grupo": ["não abriu chamado", "chamado resolvido em até 24 h", "chamado␣
 ↪acima de 24 h",
              "notificações 0-1", "notificações 2+", "nenhum dos dois sinais"],
    "clientes": [(~df["abriu_chamado"]).sum(), (df["abriu_chamado"] & ~lento).
 ↪sum(), lento.sum(), baixo.sum(), (~baixo).sum(), (~baixo & ~lento).sum()],
    "churn_%": [df.loc[m, "churn_30d"].mean() * 100 for m in
                [~df["abriu_chamado"], df["abriu_chamado"] & ~lento, lento,␣
 ↪baixo, ~baixo, ~baixo & ~lento]],
```

```
}).round(2)
conf
```

[17]:

	grupo	clientes	churn_%
0	não abriu chamado	7476	10.50
1	chamado resolvido em até 24 h	1746	10.08
2	chamado acima de 24 h	778	50.39
3	notificações 0-1	3049	25.32
4	notificações 2+	6951	8.36
5	nenhum dos dois sinais	6408	6.13